



北京化工大学
BEIJING UNIVERSITY OF CHEMICAL TECHNOLOGY



机器学习-分类学习

项德良



xiangdeliang@buct.edu.cn

2022年10月

分类的概念

2

- 虽然我们人类都不喜欢被分类，被贴标签，但数据研究的基础正是给数据“贴标签”进行分类。类别分得越精准，我们得到的结果就越有价值。
- 分类是一个**有监督的学习过程**，目标数据库中有哪些类别是已知的，分类过程需要做的就是将每一条记录归到对应的类别之中。由于必须事先知道各个类别的信息，并且所有待分类的数据条目都默认有对应的类别，因此分类算法也有其局限性，当上述条件无法满足时，我们就需要尝试聚类分析。



分类的概念

3

监督学习

在监督学习中，算法从有标记数据中学习。在理解数据之后，该算法通过将模式与未标记的新数据关联来确定应该给新数据赋哪种标签。

监督学习可以分为两类：**分类**和**回归**。

分类问题预测数据所属的类别；

分类的例子包括垃圾邮件检测、客户流失预测、情感分析、犬种检测等。

回归问题根据先前观察到的数据预测数值；

回归的例子包括房价预测、股价预测、身高-体重预测等。

分类的概念

4

区分「聚类」与「分类」

- 聚类和分类是两种不同的分析。
- 分类的目的是为了确定一个点的类别，**具体有哪些类别是已知的**，是一种有监督学习。聚类的目的是将一系列点分成若干类，事先是没有类别的，是一种无监督学习。
- 两者也有共同点，那就是它们都包含这样一个过程：对于想要分析的目标点，都会在数据集中寻找离它最近的点。

如判断邮件是否为垃圾邮件，判断在线交易是否存在潜在风险，判断肿瘤为良性还是恶性等等

分类的概念


5

分类 Classification

分类问题出现在我们训练模型预测定性目标的时候。
比如，预测性别、水果种类等。


*译者注：

我们在训练模型进行定性预测之前，要先对其输出结果分类，比如人类的性别、水果的种类等。模型只需要输出在或不在这一类中即可。



- ✓ 分类是一种基于一个或多个自变量确定因变量所属类别的技术。
- ✓ 分类用于预测**离散响应**。

逻辑回归 LOGISTIC REGRESSION



- ✓ 逻辑回归类似于线性回归，适用于因变量不是一个数值字的情况（“是/否”响应）。它虽然被称为回归，但却是基于根据回归的分类，将因变量分为两类。

分类的概念

6

回顾：逻辑回归

逻辑回归用于预测二分类的输出。例如，如果信用卡公司构建一个模型来决定是否通过向客户的发行信用卡申请，它将预测客户的信用卡是否会“违约”。

$$y = b_0 + b_1x$$

首先对变量之间的关系进行线性回归以构建模型，分类的阈值假设为0.5。

$$p = \frac{1}{1 + e^{-y}}$$

然后将Logistic函数应用于回归分析，得到两类的概率。

该函数给出了事件发生和不发生概率的对数。最后，根据这两类中较高的概率对变量进行分类。

比值
ODDS

事件发生

$$\frac{\Pr(y)}{\Pr(\sim y)}$$

事件未发生

比值是事件发生的概率与未发生的概率的比率。

ChrisAlbon

分类的概念

风中摇曳的小萝卜 

5分钟了解——机器学习算法

逻辑斯谛回归

分类的概念

8

思考问题：

**逻辑回归是回归算法还是分类算法？它
和回归算法有何不同，和分类算法有何
不同？**

一 分类问题表示及基本模型

二 **Fisher**线性判别分类

三 多类逻辑回归问题

四 朴素贝叶斯分类

一、分类问题表示及基本模型

10

分类问题 (Classification)


- 数据集 (标注集)

$$\mathcal{D} = \{(\mathbf{x}_i, \mathbf{t}_i)\}_{i=1}^N \Rightarrow \mathbf{y} = h(\mathbf{x})$$

- 分类(Classification) $\mathbf{t}, \mathbf{y} \in \{1, \dots, C\}$

$C=2$, *binary classification*

$C > 2$, *multiclass classification*



一、分类问题表示及基本模型

11

基本分类问题表示



对于2类问题

$$t \in \{0, 1\}$$

$$t = 1 \Rightarrow C1 \quad t = 0 \Rightarrow C2$$

对于K (>2)类问题 (K-to-1编码)

$$t = (0, \dots, 0, 1, 0, \dots, 0)^T$$



一、分类问题表示及基本模型

12

分类的三种基本模型

(1). 判决函数模型

线性模型


$$y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$$

广义线性模型 (generalized linear models)

$$y(\mathbf{x}) = f(\mathbf{w}^T \mathbf{x} + w_0)$$

$f(\cdot)$ 为激活函数

由训练集学习参数 $\mathbf{w}, w_0$ (或用验证集确定超参数)



判别函数 (discriminant function) 是寻找一个函数 $f(\cdot)$ 将每个输入直接映射到目标输出，这种方法无法获取后验概率。
感知器算法、线性SVM (支持向量机)、Fisher判别函数等算法都算是判别函数方法。

一、分类问题表示及基本模型

13

判决函数模型

分类的目标是将输入变量 x 分到 K 个离散的类别 C_k 中的某一类。最常见的情况是，类别互相不相交，因此每个输入被分到唯一的一个类别中。因此输入空间被划分为不同的**决策区域 (decision region)**，它的边界被称为**决策边界 (decision boundary)** 或者**决策面 (decision surface)**。


分类线性模型是指决策面是输入向量 x 的线性函数，因此被定义为 D 维输入空间中的 $(D - 1)$ 维超平面。如果数据集可以被线性决策面精确地分类，那么我们说这个数据集是**线性可分的 (linearly separable)**。

决策面对应于 $f(x) = \text{常数}$ ，即 $w^T x + w_0 = \text{常数}$ ，因此决策面是 x 的线性函数，即使函数 $f(x)$ 是非线性函数也是如此。

一、分类问题表示及基本模型

14

判决函数模型



二维线性判别函数的几何表示。决策面（红色）垂直于 w ，它距离原点的偏移量由偏置参数 w_0 决定。

$$y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$$

其中 w 被称为权向量 (weight vector)， w_0 被称为偏置 (bias)。偏置的相反数有时被称为阈值 (threshold)。当 $y(\mathbf{x})$ 大于 0 时， $\mathbf{x}$ 被分到 w_1 类，若 $y(\mathbf{x})$ 小于 0 则被分到 w_2 类。

二分类判决和多分类判决

一、分类问题表示及基本模型

15

判决函数模型

考虑两个点 x_A 和 x_B ，两个点都位于决策面上。由于 $y(x_A) = y(x_B) = 0$ ，我们有 $w^T(x_A - x_B) = 0$ ，因此向量 w 与决策面内的任何向量都正交，从而 w 确定了决策面的方向。类似地，如果 x 是决策面内的一个点，那么 $y(x) = 0$ ，因此从原点到决策面的垂直距离为

$$\frac{w^T x}{\|w\|} = -\frac{w_0}{\|x\|}$$

其中，偏置参数 w_0 确定了决策面的位置。

如何将线性判别函数扩展到多类判别？



对于 K 类 ($K > 2$) 这种多类问题来说，区域划分会遇到困难。一种方法叫做“一对其他” (one-versus-the-rest) 分类器，这种方法构造了 $K-1$ 个两类情况的判决函数。如果要判断 x 属于第 k 类，则第 k 类的判决函数 $y_k(x)$ 要大于零，且剩余其他所有判决函数都要小于零。

一、分类问题表示及基本模型

16

判决函数模型

另外一种多类问题的分类方法是“1对1”（one-versus-one）分类器，这种方法考虑了每一对二分类的情况，所以一共有 $\frac{K(K-1)}{2}$ 个判别函数。这种方法需要用许多分类器，但决策歧义区要比上一分类方法小。



此方法的缺点在于产生了输入空间中无法分类的区域。

一、分类问题表示及基本模型

17

分类的三种基本模型（续）

(2). 判决（概率）模型

由数据集直接训练后验概率，由决策论确定输出

$$p(C_k | \mathbf{x}; \mathbf{X}) \text{ 简写为 } p(C_k | \mathbf{x})$$

学习得到条件概率分布 $p(C_k | \mathbf{x})$ ，即在特征 $\mathbf{x}$ 出现的情况下标记 C_k 出现的概率。

典型方法：

贝叶斯分类器

逻辑回归

贝叶斯公式+KL散度=变分推断

一、分类问题表示及基本模型

18

判决（概率）模型

贝叶斯分类器是使用概率解决分类问题的典型代表。它的想法很简单：根据贝叶斯公式直接计算样本 x 属于每个类的概率 $p(y|x)$

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)}$$

这个概率也称为类后验概率。在这里 $p(y)$ 是每个类出现的概率， $p(x|y)$ 是类条件概率，也是每个类的样本的特征向量 x 所服从的概率分布。然后将样本判定为概率值最大的那个类

$$\arg \max_y p(x|y)p(y)$$

一、分类问题表示及基本模型

19

判决（概率）模型

logistic回归用于解决二分类问题，它的想法与贝叶斯分类器类似，也是预测样本属于每个类的概率。不同的是它没有借助于贝叶斯公式，而是直接根据特征向量 $\mathbf{x}$ 估计出了样本是正样本的概率

$$p(\mathbf{x}) = \frac{1}{1 + \exp(-(\mathbf{w}^T \mathbf{x} + b))}$$

如果这个概率值大于0.5，就被判定为正样本，否则是负样本。这里的参数 w 和 b 通过最大似然估计得到。需要强调的是，logistic回归虽然是一种概率模型，但它不是生成模型，而是判别模型，因为它没有假设样本的特征向量服从何种概率分布。

一、分类问题表示及基本模型

20

分类的三种基本模型（续）

(3). 生成（概率）模型

首先得到 $p(\mathbf{x}|C_k)$ 和 $p(C_k)$ 或: $p(\mathbf{x}, C_k)$

再由Bayes公式得

$$p(C_k|\mathbf{x}) = \frac{p(\mathbf{x}, C_k)}{p(\mathbf{x})}$$

分别计算 $p(C_k|\mathbf{x})$ ，选择三类中最大的 $p(C_k|\mathbf{x})$ 作为样本的分类。

一般会对每一个类建立一个模型，有多少个类别，就建立多少个模型。比如说类别标签有{猫，狗，猪}，那首先根据猫的特征学习出一个猫模型，再根据狗的特征学习出狗的模型，之后分别计算出新样本 $\mathbf{x}$ 跟三个类别的联合概率 $p(\mathbf{x}, C_k)$

典型方法：朴素贝叶斯

一、分类问题表示及基本模型

21

生成（概率）模型

不管是生成式模型还是判别式模型，他们最终的判断依据都是条件概率 $P(y|x)$ ，但是生成式模型先计算了联合概率 $P(x,y)$ ，再由贝叶斯公式得到条件概率。因此，生成式模型可以体现更多数据本身的分布信息，其普适性更广。

山羊绵羊的例子

判别式模型：要确定一个羊是山羊还是绵羊，用判别式模型的方法是从历史数据中学习模型，然后通过提取这只羊的特征来预测这只羊是山羊的概率，是绵羊的概率。

生成式模型：是根据山羊的特征首先学习出一个山羊的模型，然后根据绵羊的特征学习一个绵羊的模型，然后从这只羊提取特征，放到山羊模型中看概率是多少，再放到绵羊模型中看概率是多少，哪个大就是哪个。

一、分类问题表示及基本模型


22

生成（概率）模型

左边是判别式模型右边是生成式模型，判别式模型是再寻找一个决策边界，通过该边界将样本划分到对应类别。而生成式模型不同，他学习了每个类别的边界，它包含了更多训练数据本身信息，可以用来生成样本。


判别式模型和生成式模型的对比图

Discriminative vs. Generative



一、分类问题表示及基本模型

23



判别式模型特点:

判别式模型直接学习决策函数 $Y=f(x)$ 或者条件概率 $P(y|x)$, 不能反映训练数据本身的特性, 但它寻找不同类别之间的最优分割面, 反映的是异类数据之间的差异, 直接面对预测往往学习准确度更高。具体来说有以下特点:

- 对条件概率建模, 学习不同类别之间的最优边界
- 捕捉不同类别特征的差异信息, 不学习本身分布信息, 无法反映数据本身特性
- 学习成本低, 需要的计算资源较少。
- 需要的样本数可以较少, 少样本也能很好学习
- 预测时拥有较好性能
- 无法转换为生成式

生成式模型特点:

生成式模型学习的是联合概率分布 $P(x,y)$, 可以从统计的角度表示分布的情况, 能够反映同类数据本身的相似度, 它不关心到底划分不同类的边界在哪里。生成式模型的学习收敛速度更快, 当样本容量增加时, 学习到的模型可以更快的收敛到真实模型, 当存在隐变量时, 依旧可以使用生成式模型, 此时判别式方法就不行了。具体来说, 有以下特点:

- 对联合概率建模, 学习所有分类数据的分布
- 学习到的数据本身信息更多, 能反映数据本身特性
- 学习成本较高, 需要更多的计算资源
- 需要的样本数更多, 样本较少时学习效果较差。
- 推断时性能较差。
- 一定条件下能转换成判别式。

一 分类问题表示及基本模型


二 **Fisher**线性判别分类

三 多类逻辑回归问题

四 朴素贝叶斯分类

二、Fisher线性判别分类

25



思想

Fisher的目的是将高维的数据投影到一维直线上并在投影的值中取一个阈值进行分类。



很明显左边的投影更适合分类，因为两种类别（o和x）在投影直线上能轻松地找到一个阈值将其区分开来，而右边的投影方向则不适合当前分类。

1. 问题的初衷在于找到一条线将坐标点向该线上投影，将这条线的方向设为 w ，并用该 w 作为假设带入，最后解出最佳 w
2. 将样本点向该直线中投影，即 $w^T x$ ，求出每一类样本点在投影上的均值和方差（或者说是协方差矩阵）
3. 按照类间小，类内大的目标，设立目标函数求解 w

二、Fisher线性判别分类

26

Fisher线性判别分析方法是一种降维的方法，考虑二分类情况的话，此方法可以看作是把所有样本投影到一个方向上，然后在该方向上确定一个分类阈值，过这个阈值点且与投影方向垂直的超平面就是分类平面。那么**投影方向**要如何寻找呢？**Fisher判别方法考虑的准则就是投影后的样本若是同一类则尽可能的聚集，若是不同类则要尽可能的分散。**



二、Fisher线性判别分类

27

训练样本集为 $\{x_1, \dots, x_N\}$ ，每个样本是一个d维向量，其中 ω_1 类的样本是 $\{x_1^1, \dots, x_{N_1}^1\}$ ，属于 ω_2 类的样本是 $\{x_1^2, \dots, x_{N_2}^2\}$ ，寻找一个投影方向 w ，投影以后的样本变为 $y_i = w^T x_i$ ，定义每一类的类均值向量为 $m_i = \frac{1}{N_i} \sum_{x_j \in \omega_i} x_j, i = 1, 2$

为了定量分析类内聚集和类间分开的程度，我们定义类内离散度矩阵和类间离散度矩阵。

在原样本空间中

各类的类内离散度矩阵为

$$S_i = \sum_{x_j \in \omega_i} (x_j - m_i)(x_j - m_i)^T, i = 1, 2$$

总类内离散度为 $S_w = S_1 + S_2$

类间离散度矩阵为 $S_b = (m_1 - m_2)(m_1 - m_2)^T$

Fisher投影



投影以后的一维空间中，两类的均值为

$$\tilde{m}_i = \frac{1}{N_i} \sum_{y_j \in \omega_i} y_j = w^T m_i, i = 1, 2$$

投影以后，类内离散度不再是一个矩阵，而是一个值

$$\tilde{S}_i^2 = \sum_{y_j \in \omega_i} (y_j - \tilde{m}_i)^2, i = 1, 2$$

总类内离散度为 $\tilde{S}_w = \tilde{S}_1^2 + \tilde{S}_2^2$

类间离散度变为了两类均值差的平方 $\tilde{S}_b = (\tilde{m}_1 - \tilde{m}_2)^2$

二、Fisher线性判别分类

28

我们希望投影后的类内离散度小，而类间离散度大，即可以表示成如下准则

$$\max J(w) = \frac{\tilde{S}_b}{\tilde{S}_w} = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{S}_1^2 + \tilde{S}_2^2}$$

上式就是Fisher准则函数，可以将其写为矩阵形式

$$\max J(w) = \frac{w^T S_b w}{w^T S_w w}$$


这个表达式也被称为瑞丽（Rayleigh）商，在许多优化问题中都有出现。这个问题的解为(用求导的方法可以得到，这里略去推导过程)

$$w^* = S_w^{-1}(m_1 - m_2)$$

如何推导？

这就是Fisher准则下的最优投影方向，但是分类面并未直接给出。要得到分类面即确定一个分类阈值使得若 $g(x) = w^T x + w_0 > 0$ ，则 $x \in \omega_1$ ；若 $g(x) < 0$ ，则 $x \in \omega_2$ 。通常我们可以取阈值 w_0 为投影后两类均值的中间即

$$w_0 = -\frac{1}{2}(w^T \tilde{m}_1 + w^T \tilde{m}_2)$$



粉色线是什么？

二、Fisher线性判别分类

29

由类内紧致，类间分离准则确定投影方向，我们可以定义如下类内距离和类间距离：

$$\tilde{m}_i = \frac{1}{n_i} \sum_{y_j \in X_i}^{i=1,2} y_j = \frac{1}{n_i} \sum_{y_j \in X_i}^{i=1,2} w^T x_j = w^T m_i$$

其中 $\tilde{m}_i$ 表示降维后的类中心， m_i 表示原始空间的类中心。

类内距离：

$$\begin{aligned} \tilde{S}_w &= \sum_{y_j \in X_i}^{i=1,2} (y_j - \tilde{m}_i)^2 \\ &= \sum_{x_j \in X_i}^{i=1,2} \left(w^T x_j - \frac{1}{n_i} \sum_{x_j \in X_i} w^T x_j \right)^2 \\ &= w^T \sum_{x_j \in X_i}^{i=1,2} \left(x_j - \frac{1}{n_i} \sum_{x_j \in X_i} x_j \right)^2 w \\ &= w^T S_w w \end{aligned}$$

其中 $S_w = \sum_{x_j \in X_i}^{i=1,2} (x_j - m_i)^2$ 表示每类样本在原始空间的一个类内距离。

类间距离：

$$\begin{aligned} \tilde{S}_b &= (\tilde{m}_1 - \tilde{m}_2)^2 \\ &= \left(\frac{1}{n_1} \sum_{x_j \in X_1} w^T x_j - \frac{1}{n_2} \sum_{x_j \in X_2} w^T x_j \right)^2 \\ &= w^T \left(\frac{1}{n_1} \sum_{x_j \in X_1} x_j - \frac{1}{n_2} \sum_{x_j \in X_2} x_j \right)^2 w \\ &= w^T S_b w \end{aligned}$$

其中 $S_b = \sum_{x_j \in X_i}^{i=1,2} (m_1 - m_2)^2$ 表示每类样本在原始空间的一个类间距离。

所以为了使类内紧致，类间分离，可以最大化如下目标函数：

$$\max J(w) = \frac{\tilde{S}_b}{\tilde{S}_w} = \frac{w^T S_b w}{w^T S_w w}$$

等价于 $\max(w^T S_b w) s.t. w^T S_w w = c$ ，由拉格朗日乘子法有：

$$L(w, \lambda) = w^T S_b w - \lambda(w^T S_w w - c)$$


二、Fisher线性判别分类

30

- 一 分类问题表示及基本模型
- 二 **Fisher**线性判别分类
- 三 多类逻辑回归问题
- 四 朴素贝叶斯分类


三、多类逻辑回归问题

32



如何实现多类别分类呢?

逻辑回归其实是在线性回归的基础上，套用了—个逻辑函数。上图的 $y(z)$ 就是这个逻辑函数(或称为Sigmoid函数)。下面左图是一个线性的决策边界，右图是非线性的决策边界。





三、多类逻辑回归问题

下面是一个典型的多分类任务，存在0至9共10个类别。那么如何将二分类逻辑回归模型扩展至多分类的情况呢？


一种直观的想法便是，对于每个类别都单独训练一个二分类逻辑回归模型，该模型解决的是判断样本是否属于这一类的问题。

4	7	3	7	7	7	8	6	3	9
\	0	3	1	7	6	3	8	1	0
8	3	4	4	5	0	0	3	6	0
9	9	1	2	4	7	4	8	5	9
7	5	9	8	4	0	2	9	9	1
4	7	6	7	9	2	9	7	7	2
9	3	5	2	5	0	5	0	4	0
2	1	7	3	7	4	8	1	2	7
9	9	0	6	6	6	6	5	2	9
7	7	1	8	4	9	0	5	2	0



三、多类逻辑回归问题

34




Class 1: 


Class 2: 

Class 3: 


$$h_{\theta}^{(i)}(x) = P(y = i|x; \theta)$$



$$h_{\theta}^{(1)}(x) = P(y = 1|x; \theta)$$



$$h_{\theta}^{(2)}(x) = P(y = 2|x; \theta)$$



$$h_{\theta}^{(3)}(x) = P(y = 3|x; \theta)$$

共存在三角（Class 1）、方块（Class 2）、叉叉（Class 3）三个类别，实现上述三个类别的划分共需训练 3 个二分类逻辑回归模型：其中， $h_{\theta}^{(1)}(x)$ 用于区分三角和非三角； $h_{\theta}^{(2)}(x)$ 用来区分方块和非方块； $h_{\theta}^{(3)}(x)$ 用于区分叉叉和非叉叉。这便是 One-vs-all 分类的基本思想。

三、多类逻辑回归问题

35

One-vs-all分类基本思想:

- 对于每个类别 i , 单独训练一个二分类逻辑回归模型 $h_{\theta}^{(i)}(x)$ 用于预测样本属于类别 i ($y = i$) 的概率
- 对于新的输入 x , 选择最大化 $h_{\theta}^{(i)}(x)$ 的类别 i 作为 x 的预测类别

对于一个三分类问题, 我们最终得到 3 个二元分类器。在预测阶段, 每个分类器可以根据测试样本, 得到当前正类的概率, 即 $P(y = i | x; \theta)$, $i = 1, 2, 3$ 。选择计算概率结果最高的分类器, 其正类就可以作为预测结果。

【优点】 普适性比较广, 可以应用于能输出值或者概率的分类器, 同时效率相对较好, 有多少个类别就训练多少个分类器。

【缺点】 很容易造成训练集样本数量的不平衡 (Unbalance), 尤其在类别较多的情况下, 经常容易出现正类样本的数量远远不及负类样本的数量, 这样就会造成分类器的偏向性。



三、多类逻辑回归问题

36

在二元的逻辑回归模型中，我们用 Sigmoid 函数将一个多维数据（一个样本）映射到一个 0 - 1 之间的数值上，有没有什么方法从数学上让一个样本映射到多个 0 - 1 之间的数值呢？答案是通过 Softmax 函数。

损失函数：

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m \sum_{j=1}^k 1\{y^{(i)} = j\} \log \frac{e^{\theta_j^T x^{(i)}}}{\sum_{l=1}^k e^{\theta_l^T x^{(i)}}} \right]$$

求导后，可得

$$\nabla_{\theta_j} J(\theta) = -\frac{1}{m} \sum_{i=1}^m [x^{(i)} (1\{y^{(i)} = j\} - p(y^{(i)} = j|x^{(i)}; \theta))]$$

更新参数：

$$\theta_j := \theta_j - \alpha \nabla_{\theta_j} J(\theta)$$

在softmax回归中，我们对多类分类感兴趣（而不是仅对二元分类），所以 y 可以取 k 个不同的取值。因此，在我们的训练集 $\{(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})\}$ ，其中 $y^{(i)} \in \{1, 2, \dots, k\}$

给定测试输入 x ，我们希望模型估计每个类别的概率。因此，模型将输出 k 维向量（其元素总和为 1），给出 k 个类别的估计概率。具体地说，我们的假设 $h_{(\theta)}(x^{(i)})$ 采用以下形式：

$$h_{\theta}(x^{(i)}) = \begin{bmatrix} p(y^{(i)} = 1|x^{(i)}; \theta) \\ p(y^{(i)} = 2|x^{(i)}; \theta) \\ \vdots \\ p(y^{(i)} = k|x^{(i)}; \theta) \end{bmatrix} = \frac{1}{\sum_{j=1}^k e^{\theta_j^T x^{(i)}}} \begin{bmatrix} e^{\theta_1^T x^{(i)}} \\ e^{\theta_2^T x^{(i)}} \\ \vdots \\ e^{\theta_k^T x^{(i)}} \end{bmatrix}$$

其中， $\theta_1, \theta_2, \dots, \theta_k \in R^{n+1}$ 是模型的参数，而 $\frac{1}{\sum_{j=1}^k e^{\theta_j^T x^{(i)}}}$ 是归一化项。

为了方便起见，用向量法来表示模型的所有参数。当实现 softmax 回归时，将 θ 表示为通过堆叠 $\theta_1, \theta_2, \dots, \theta_k$ 成行获得的 $k * (n + 1)$ 的矩阵通常很方便，这样

$$\theta = \begin{bmatrix} -\theta_1^T \\ -\theta_2^T \\ \vdots \\ -\theta_k^T \end{bmatrix}$$

- 一 分类问题表示及基本模型
- 二 **Fisher**线性判别分类
- 三 多类逻辑回归问题
- 四 朴素贝叶斯分类

四、朴素贝叶斯分类

38

贝叶斯分类：贝叶斯分类是一类分类算法的总称，这类算法均以贝叶斯定理为基础，故统称为贝叶斯分类。

先验概率：根据以往经验和分析得到的概率。我们用 $P(Y)$ 来代表在没有训练数据前假设 Y 拥有的初始概率。

后验概率：根据已经发生的事件来分析得到的概率。以 $P(Y|X)$ 代表假设 X 成立的情下观察到 Y 数据的概率，因为它反映了在看到训练数据 X 后 Y 成立的置信度。

四、朴素贝叶斯分类

39

联合概率： 联合概率是指在多元的概率分布中多个随机变量分别满足各自条件的概率。 X 与 Y 的联合概率表示为 $P(X, Y)$ 、 $P(XY)$ 或 $P(X \cap Y)$ 。

假设 X 和 Y 都服从正态分布，那么 $P(X < 5, Y < 0)$ 就是一个联合概率，表示 $X < 5, Y < 0$ 两个条件同时成立的概率。表示两个事件共同发生的概率。

四、朴素贝叶斯分类

40

贝叶斯公式

后验概率

似然度

先验概率

$$P(Y|X) = \frac{P(X, Y)}{P(X)} = \frac{P(X|Y)P(Y)}{P(X)}$$

边缘似然度

我们最终求的 $p(\text{类别}|\text{特征})$ 即可

$$p(\text{类别}|\text{特征}) = \frac{p(\text{特征}|\text{类别})p(\text{类别})}{p(\text{特征})}$$

朴素贝叶斯法是典型的生成学习方法。生成方法由训练数据学习联合概率分布 $P(X, Y)$ ，然后求得后验概率分布 $P(Y|X)$ 。

具体来说，利用训练数据学习 $P(X|Y)$ 和 $P(Y)$ 的估计，得到联合概率分布：

$$P(X, Y) = P(X|Y) P(Y)$$

四、朴素贝叶斯分类

41

风中摇曳的小萝卜 bilibili

5分钟了解——机器学习算法

朴素贝叶斯法

四、朴素贝叶斯分类

42

判别模型和生成模型

监督学习方法又分
生成方法（Generative approach）和**判别方法**（Discriminative approach）
所学到的模型分别称为
生成模型（Generative Model）和**判别模型**（Discriminative Model）。

判别模型（Discriminative Model）	生成模型（Generative Model）
由数据直接学习决策函数 $Y=f(X)$ 或者条件概率分布 $P(Y X)$ 作为预测的模型，即判别模型。基本思想是有限样本条件下建立判别函数，不考虑样本的产生模型，直接研究预测模型。 即：直接估计 $P(Y X)$	由训练数据学习联合概率分布 $P(X,Y)$ ，然后求得后验概率分布 $P(Y X)$ 。具体来说，利用训练数据学习 $P(X Y)$ 和 $P(Y)$ 的估计，得到联合概率分布： $P(X,Y) = P(Y)P(X Y)$ ，再利用它进行分类。 即：估计 $P(X Y)$ 然后推导 $P(Y X)$
线性回归、逻辑回归、感知机、决策树、支持向量机.....	朴素贝叶斯、HMM、深度信念网络(DBN).....

四、朴素贝叶斯分类

43

1. 朴素贝叶斯法是典型的生成学习方法。

生成方法由训练数据学习联合概率分布 $P(X, Y)$ ，然后求得后验概率分布 $P(Y|X)$ 。具体来说，利用训练数据学习 $P(X|Y)$ 和 $P(Y)$ 的估计，得到联合概率分布：

$$P(X, Y) = P(Y)P(X|Y)$$

概率估计方法可以是极大似然估计或贝叶斯估计。

四、朴素贝叶斯分类

44

2. 朴素贝叶斯法的基本假设是条件独立性。

$$P(X = x|Y = c_k) = P(x^{(1)}, \dots, x^{(n)}|y^k) = \prod_{j=1}^n P(x^{(j)}|Y = c_k)$$

c_k 代表类别， k 代表类别个数。

这是一个较强的假设。由于这一假设，模型包含的条件概率的数量大为减少，朴素贝叶斯法的学习与预测大为简化。因而朴素贝叶斯法高效，且易于实现。其缺点是分类的性能不一定很高。朴素贝叶斯算法都认为这些特征都是独立的。这样的假设过于理想，朴素贝叶斯因此而得名。

四、朴素贝叶斯分类

45

3. 朴素贝叶斯法利用贝叶斯定理与学到的联合概率模型进行分类预测

我们要求的是 $P(Y|X)$ ，根据生成模型定义我们可以求 $P(X, Y)$ 和 $P(Y)$ 假设中的特征是条件独立的。这个称作朴素贝叶斯假设。形式化表示为，（如果给定 Z 的情况下， X 和 Y 条件独立）：

$$P(X|Z) = P(X|Y, Z)$$

也可以表示为：

$$P(X, Y|Z) = P(X|Z)P(Y|Z)$$

四、朴素贝叶斯分类

46

用于文本分类的朴素贝叶斯模型，这个模型称作多值伯努利事件模型。

在这个模型中，我们首先随机选定了邮件的类型 $p(y)$ ，然后一个人翻阅词典的所有词，随机决定一个词是否出现依照概率 $p(x^{(1)}|y)$ ，出现标示为1，否则标示为0。假设有50000个单词，那么这封邮件的概率可以表示为：

$$\begin{aligned} & p(x^{(1)}, \dots, x^{(50000)} | y) \\ &= p(x^{(1)} | y) p(x^{(2)} | y, x^{(1)}) p(x^{(3)} | y, x^{(1)}, x^{(2)}) \cdots p(x^{(50000)} | y, x^{(1)}, \dots, x^{(49999)}) \\ &= p(x^{(1)} | y) p(x^{(2)} | y) p(x^{(3)} | y) \cdots p(x^{(50000)} | y) \\ &= \prod_{i=1}^m p(x^{(i)} | y) \end{aligned}$$

四、朴素贝叶斯分类

47

独立性

将输入 x 分到后验概率最大的类 y 。

$$y = \operatorname{argmax}_{c_k} P(Y = c_k) \prod_{j=1}^n P(X_j = x^{(j)} | Y = c_k)$$

后验概率最大等价于0-1损失函数时的期望风险最小化。

四、朴素贝叶斯分类

48

$$y = \operatorname{argmax}_{c_k} P(Y = c_k) \prod_{j=1}^n P(X_j = x^{(j)} | Y = c_k)$$

$X = \{x_1, x_1, \dots, x_n\}$ ，为 n 维向量的集合

$Y = \{c_1, c_2, \dots, c_k\}$ ， K 为类别数

训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ 由 $P(X, Y)$ 独立同分布产生。

四、朴素贝叶斯分类

49

朴素贝叶斯法对**条件概率分布作了条件独立性的假设**。由于这是一个较强的假设，朴素贝叶斯法也由此得名。具体地，条件独立性假设是：

$$\begin{aligned} P(X = x|Y = c_k) &= P(X^{(1)} = x^{(1)}, X^{(2)} = x^{(2)}, \dots, X^{(n)} = x^{(n)}|Y = c_k) \\ &= \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_k) \end{aligned} \quad (1)$$

四、朴素贝叶斯分类

50

朴素贝叶斯法分类时，对给定的输入 x ，通过学习到的模型计算后验概率分布 $P(Y = c_k|X = x)$ ，将后验概率最大的类作为 x 的类输出。根据贝叶斯定理：

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

可以计算后验概率

$$P(Y = c_k|X = x) = \frac{P(X = x|Y = c_k)P(Y = c_k)}{\sum_{k=1}^K P(X = x|Y = c_k)P(Y = c_k)} \#(2)$$

四、朴素贝叶斯分类

51

将式(1)代入公式(2), 可以得到

$$P(Y = c_k | X = x) = \frac{\prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k) P(Y = c_k)}{\sum_{k=1}^K \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k) P(Y = c_k)}$$

贝叶斯分类器可以表示为:

$$y = f(x) = \operatorname{argmax}_{c_k} \frac{\prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k) P(Y = c_k)}{\sum_{k=1}^K \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k) P(Y = c_k)}$$

上式中分母中 c_k 都是一样的, 即不会对结果产生影响, 即

$$y = f(x) = \operatorname{argmax}_{c_k} \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k) P(Y = c_k)$$

四、朴素贝叶斯分类


52

整个朴素贝叶斯分类分为三个阶段：

第一阶段——准备工作阶段，主要工作是根据具体情况确定特征属性，并对每个特征属性进行适当划分，由人工对一部分待分类项进行分类，形成训练样本集合。这一阶段的输入是所有待分类数据，输出是特征属性和训练样本。这一阶段是整个朴素贝叶斯分类中唯一需要人工完成的阶段，其质量对整个过程将有重要影响，分类器的质量很大程度上由特征属性、特征属性划分及训练样本质量决定。

第二阶段——分类器训练阶段，这个阶段的任務就是生成分类器，主要工作是计算每个类别在训练样本中的出现频率及每个特征属性划分对每个类别的条件概率估计，并将结果记录。其输入是特征属性和训练样本，输出是分类器。这一阶段是机械性阶段，根据前面讨论的公式可以由程序自动计算完成。

第三阶段——应用阶段。这个阶段的任務是使用分类器对待分类项进行分类，其输入是分类器和待分类项，输出是待分类项与类别的映射关系。这一阶段也是机械性阶段，由程序完成。



四、朴素贝叶斯分类

53

等价于这样描述

- 1、设 $x = \{a_1, a_2, \dots, a_m\}$ 为一个待分类项，而每个 a 为 x 的一个特征属性。
- 2、有类别集合 $C = \{y_1, y_2, \dots, y_n\}$ 。
- 3、计算 $P(y_1|x), P(y_2|x), \dots, P(y_n|x)$ 。
- 4、如果 $P(y_k|x) = \max\{P(y_1|x), P(y_2|x), \dots, P(y_n|x)\}$ ，则 $x \in y_k$ 。

四、朴素贝叶斯分类

54

那么现在的关键就是如何计算第3步中的各个条件概率。我们可以这么做：

1、找到一个已知分类的待分类项集合，这个集合叫做训练样本集。

2、统计得到在各类别下各个特征属性的条件概率估计。即

$$P(a_1|y_1), P(a_2|y_1), \dots, P(a_m|y_1); P(a_1|y_2), P(a_2|y_2), \dots, P(a_m|y_2); \dots; P(a_1|y_n), P(a_2|y_n), \dots, P(a_m|y_n)$$

。

3、如果各个特征属性是条件独立的，则根据贝叶斯定理有如下推导：

$$P(y_i|x) = \frac{P(x|y_i)P(y_i)}{P(x)}$$

因为分母对于所有类别为常数，因为我们只要将分子最大化皆可。又因为各特征属性是条件独立的，所以有：

$$P(x|y_i)P(y_i) = P(a_1|y_i)P(a_2|y_i)\dots P(a_m|y_i)P(y_i) = P(y_i) \prod_{j=1}^m P(a_j|y_i)$$

四、朴素贝叶斯分类

55

这一节讨论 $P(a|y)$ 的估计。

由上文看出，计算各个划分的条件概率 $P(a|y)$ 是朴素贝叶斯分类的关键性步骤，当特征属性为离散值时，只要很方便的统计训练样本中各个划分在每个类别中出现的频率即可用来估计 $P(a|y)$ ，下面重点讨论特征属性是连续值的情况。

当特征属性为连续值时，通常假定其值服从高斯分布（也称正态分布）。即：

$$g(x, \eta, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x - \eta)^2}{2\sigma^2}}$$

$$\text{而 } P(a_k|y_i) = g(a_k, \eta_{y_i}, \sigma_{y_i})$$

因此只要计算出训练样本中各个类别中此特征项划分的各均值和标准差，代入上述公式即可得到需要的估计值。均值与标准差的计算在此不再赘述。

另一个需要讨论的问题就是当 $P(a|y)=0$ 怎么办，当某个类别下某个特征项划分没有出现时，就是产生这种现象，这会令分类器质量大大降低。为了解决这个问题，我们引入Laplace校准，它的思想非常简单，就是对没类别下所有划分的计数加1，这样如果训练样本集数量充分大时，并不会对结果产生影响，并且解决了上述频率为0的尴尬局面。

四、朴素贝叶斯分类-案例

56

拉普拉斯平滑是一种用于平滑分类数据的技术。引入拉普拉斯平滑法来解决零概率问题,通过应用此方法,先验概率和条件概率可以写为

$$P_{\lambda}(C_k) = P_{\lambda}(Y = C_k) = \frac{\sum_{i=1}^N I(y_i = C_k) + \lambda}{N + K\lambda}$$

$$P_{\lambda}(x_i = a_j | y = C_k) = \frac{\sum_{i=1}^N I(x_i = a_j, y_i = C_k) + \lambda}{\sum_{i=1}^N I(y_i = C_k) + A\lambda}$$

其中 K 表示类别数量, A 表示 a_j 中不同值的数量通常 $\lambda = 1$

加入拉普拉斯平滑之后, 避免了出现概率为0的情况, 又保证了每个值都在0到1的范围内, 又保证了最终和为1的概率性质。

四、朴素贝叶斯分类-案例

假设我们正在构建一个分类器，该分类器说明文本是否与运动(Sports)有关。我们的训练数据有5句话：

文本	标签
A great game	Sports
The election was over	Not Sports
Very clean match	Sports
A clean but forgettable game	Sports
It was a close election	Not Sports

我们想要计算句子 “A very close game” 是 Sports 的概率以及它不是 Sports 的概率。
即 $P(\text{Sports} \mid \text{a very close game})$ 这个句子的类别是Sports的概率

四、朴素贝叶斯分类-案例

58

特征：单词的频率

已知贝叶斯定理 $P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$ ，则：

$$\begin{aligned} &P(\text{Sports} \mid \text{a very close game}) \\ &= \frac{P(\text{a very close game} \mid \text{Sports}) \times P(\text{Sports})}{P(\text{a very close game})} \end{aligned}$$

由于我们只是试图找出哪个类别有更大的概率，可以舍去除数，只是比较

$P(\text{a very close game} \mid \text{Sports}) \times P(\text{Sports})$ 和

$P(\text{a very close game} \mid \text{Not Sports}) \times P(\text{Not Sports})$

四、朴素贝叶斯分类-案例

59

我们假设一个句子中的每个单词都与其他单词无关。

$$\begin{aligned} &P(a \text{ very close game }) \\ &= P(a) \times P(\text{very}) \times P(\text{close}) \times P(\text{game}) \end{aligned}$$

$$\begin{aligned} &P(a \text{ very close game} | Sports) \\ &= P(a | Sports) \times P(\text{very} | Sports) \times P(\text{close} | Sports) \times P(\text{game} | Sports) \end{aligned}$$

四、朴素贝叶斯分类-案例

60

计算每个类别的先验概率:

对于训练集中的给定句子,

$P(\text{Sports})$ 的概率为 $\frac{3}{5}$ 。

$P(\text{Not Sports})$ 是 $\frac{2}{5}$ 。

文本	标签
A great game	Sports
The election was over	Not Sports
Very clean match	Sports
A clean but forgettable game	Sports
It was a close election	Not Sports

然后, 在计算 $P(\text{game}|\text{Sports})$ 就是 “game” 有多少次出现在 Sports 的样本, 然后除以 sports 为标签的文本的单词总数 ($3+3+5=11$)。

因此, $P(\text{game}|\text{Sports}) = \frac{2}{11}$ 。

“close” 不会出现在任何 sports 样本中! 那就是说 $P(\text{close}|\text{Sports}) = 0$ 。

四、朴素贝叶斯分类-案例

61

通过使用一种称为**拉普拉斯平滑**的方法：我们为每个计数加1，因此它永远不会为零。为了平衡这一点，我们将可能单词的数量添加到除数中，因此计算结果永远不会大于1。



14个单词

在这里的情况下，可能单词是['a', 'great', 'very', 'over', 'it', 'but', 'game', 'election', 'clean', 'close', 'the', 'was', 'forgettable', 'match']。

由于可能的单词数是14，因此应用平滑处理可以得到

$$P(\text{game} \mid \text{sports}) = \frac{2+1}{11+14}$$

四、朴素贝叶斯分类-案例

62

Word	P (word Sports)	P (word Not Sports)
------	-------------------	-----------------------

a

$$P(a | \text{Sports}) \times P(\text{very} | \text{Sports}) \times P(\text{close} | \text{Sports}) \times P(\text{game} | \text{Sports}) \times P(\text{Sports}) \\ = 2.76 \times 10^{-5} = 0.0000276$$

$$P(a | \text{Not Sports}) \times P(\text{very} | \text{Not Sports}) \times P(\text{close} | \text{Not Sports}) \\ \times P(\text{game} | \text{Not Sports}) \times P(\text{Not Sports}) \\ = 0.572 \times 10^{-5} = 0.00000572$$

A photograph of a modern, multi-story building at night. The building's facade is illuminated with horizontal bands of warm yellow light. The foreground is a dark, blue-tinted area with some architectural elements and a few parked cars. The overall atmosphere is serene and modern.

谢谢!