矩阵论

线性空间与线性变换

1. 线性空间

1.1. 线性空间的概念

设 V 是一个以$\alpha, \beta, \gamma, \ldots$为元素的非空集合, F是一个数域. 在其中定义两种运算, 一种叫加法: $\forall \alpha, \beta \in V$, $\alpha + \beta \in V$; 另一种叫数量乘法：$\forall k \in F, \alpha \in F, k\alpha \in F$, 并且满足下面八条运算法则:

- 满足加法结合律;
- 满足加法交换律;
- V中存在零元素: $\exists \alpha_0 \in V, \forall \alpha \in V, \alpha + \alpha_0 = \alpha$;
- 存在负元素;
- 数乘结合律;
- 存在单位元;
- 满足数乘分配律;

则称V是数域F上的线性空间, V中的元素为向量.

1.2. 线性空间的基与维数

1.2.1. 基

设线性空间V, 若存在一组向量$B = \{\alpha_1, \alpha_2, \ldots, \alpha_n\} \subset V$, 对于该线性空间的所有元素均可被$B$中的向量线性表示, 则称$B$为线性空间$V$的一组基, 基中向量的个数为该线性空间的维度, 记作$\dim V = n$.

1.2.2. 坐标

设线性空间V, 其中的一组基为$B = \{\alpha_1, \alpha_2, \ldots, \alpha_n\}$, 则有$\forall \gamma \in V, \gamma = \sum_{i=1}^{n} \lambda_i \alpha_i$, 其中$(\lambda_1, \lambda_2, \ldots, \lambda_n)$为向量$\gamma$在基$B = \{\alpha_1, \alpha_2, \ldots, \alpha_n\}$下的坐标.

1.2.3. 基的变换

设$B_1 = \{\alpha_1, \alpha_2, \ldots, \alpha_n\}, B_2 = \{\beta_1, \beta_2, \ldots, \beta_n\}$为线性空间$V_n(F)$的两组基, 存在矩阵$C \in F^{n \times n}$, 使得$B_2 = B_1 C$, 则称矩阵$C$为基$B_1$到基$B_2$的过度矩阵.

1.3. 子空间

设线性空间V, 存在非空集合$W \subset V$, 若W的元素关于V中加法与数乘向量法运算也构成线性空间, 则称W是V的一个子空间.

非空集合W为V的子空间的充分必要条件为非空集合W中的元素对向量加法和数乘封闭.

对于线性空间V的子空间W_1, W_2, 其维度有以下关系:

$$\dim W_1 + \dim W_2 = \dim(W_1 + W_2) + \dim(W_1 \cap W_2)$$

1.3.1. 子空间的运算

设线性空间V, W_1, W_2为V的子空间

- 交运算: $W_1 \cap W_2 = \{\alpha | \alpha \in W_1 \wedge \alpha \in W_2\}$;
- 和运算: $W_1 + W_2 = \{\alpha_1 + \alpha_2 | \alpha_1 \in W_1, \alpha_2 \in W_2\}$;
- 直和: 若$W = W_1 + W_2$, 且$W_1 \cap W_2 = \emptyset$, 则称W为W_1, W_2的直和子空间, 记作$W = W_1 \oplus W_2$.

对于矩阵$A = \{\alpha_1, \alpha_2, \ldots, \alpha_n\} \in F^{m \times n}$, 其列空间和零空间可定义为:

- 零空间: $R(A) = \{x | Ax = 0, x \in F^n\}$;
- 列空间: $N(A) = \{y | y = Ax, x \in F^n\} = L\{\alpha_1, \alpha_2, \ldots, \alpha_n\}$.

2. 线性变换

设$V_n(F)$是一个线性空间, 若$V_n(F)$上的对应关系T, 使$\forall \alpha \in V_n(F)$, 都有确定的向量$\beta = T(\alpha) \in V_n(F)$与之对应, 则称$T$为$V_n(F)$上的一个变换. 又若线性空间中的线性运算, 满足

1. $\forall \alpha, \beta \in V_n(F), T(\alpha + \beta) = T(\alpha) + T(\beta)$;
2. $\forall k \in F, \forall \alpha \in V_n(F), T(k\alpha) = kT(\alpha)$,

则称T是线性空间$V_n(F)$上的一个线性变换.

2.1. 相似变换

线性空间$V_n(F)$上的相似变换定义为: $\forall \alpha \in V_n(F), T(\alpha) = \lambda\alpha$.

1. $\lambda = 0$时, 为零变换;
2. $\lambda = 1$时, 为恒等变换.

2.2. 线性变换的矩阵

对于$V_n(F)$上的线性变换T, $\{\alpha_1, \alpha_2, \ldots, \alpha_n\}$为$V_n(F)$的基, 若存在$n$阶方阵$A \in F_{n\times n}$, 使得

$$T(\alpha_1, \alpha_2, \ldots, \alpha_n) = (\alpha_1, \alpha_2, \ldots, \alpha_n)A$$

则称A是线性变换T在基$\{\alpha_1, \alpha_2, \ldots, \alpha_n\}$下的矩阵.

对于V_n到V_m上的线性变换T, 其核和值域定义如下:

- 核: $N(T) = \{x|Tx = 0, x \in V_n\}$, 维度称之为零度, 记作$\mathrm{null}T$;
- 值域: $R(T) = \{y|y = Tx, y \in V_m\}$, 维度称之为秩, 记作$\mathrm{rank}T$.
- $\mathrm{null}T + \mathrm{rank}T = n$

Jordan标准型

1. 对角化

1.1. 特征子空间

对于矩阵$A \in F^{n\times n}$, 存在集合满足

$$V = \{\alpha|A\alpha = \lambda_0\alpha, \alpha \in F^n\}$$

则称该集合为矩阵A对于λ_0的特征子空间, 其中, λ_0称为特征值.
$\dim V$为λ_0的几何重数.

1.2. 线性变换的对角化

1.3. 矩阵的对角化

2. Jordan矩阵

形如

$$J(\lambda) = \begin{pmatrix} \lambda & 1 & & & \\ & \lambda & 1 & & \\ & & \lambda & & \\ & & & \ddots & \\ & & & & \lambda \end{pmatrix}$$

的一个r阶方阵成为一个Jordan块. 由若干个Jordan块构建成的准对焦矩阵称为Jordan块, 形如

$$J = diag(J(\lambda_1), J(\lambda_2), \ldots, J(\lambda_n))$$

3. Jordan标准型的计算方法

对于矩阵$A \in F^{n\times n}$, 其Jordan标准型可按如下步骤计算:
第一步 计算矩阵的特征方程

$$f(\lambda) = |A - \lambda E| = (\lambda - \lambda_1)^{k_1}(\lambda - \lambda_2)^{k_2}\ldots(\lambda - \lambda_s)^{k_s}$$

其中, k_i表示λ_i的代数重数, 且$\sum_{i=1}^{s} k_i = n$.

第二步 计算矩阵各特征值对应的特征向量

$$\begin{gathered} B(\lambda_1) = \{\xi_{11}, \xi_{12}, \ldots, \xi_{1n_1}\} \\ B(\lambda_2) = \{\xi_{21}, \xi_{22}, \ldots, \xi_{2n_2}\} \\ \cdots \\ B(\lambda_s) = \{\xi_{s1}, \xi_{s2}, \ldots, \xi_{sn_s}\} \end{gathered}$$

其中, n_i表示λ_i的几何重数, 且$n_i \le k_i$.

第三步 计算矩阵各特征值对应的广义特征向量
对于特征值λ_i, 当$n_i = k_i$时, 即几何重数与代数重数相等时, 广义特征向量为$B(\lambda_i)$. 当$n_i < k_i$时, 其广义特征向量计算方式如下:

由特征向量ξ_{i1}, 可以得到广义特征向量

$$
\begin{gathered}
(A-\lambda_i E)\xi_{i1}=0 \\
(A-\lambda_i E)\gamma_{i2}=\xi_{i1} \\
(A-\lambda_i E)\gamma_{i3}=\gamma_{i2} \\
\cdots \\
(A-\lambda_i E)\gamma_{id_1}=\gamma_{id_1-1}
\end{gathered}
$$

记作$P(\xi_{i1})=\{\xi_{i1},\gamma_{i2},\ldots,\gamma_{id_1}\}$.
同理可得$\xi_{i2},\ldots,\xi_{in_i}$的特征向量$P(\xi_{i2}),\ldots,P(\xi_{in_i})$, d_j表示特征向量ξ_{ij}对应的广义特征向量个数或该特征向量对应的Jordan块$J_j(\lambda_i)$阶数, 且$\sum_{j=1}^{n_i} d_j=k_i$.

第四步 得到Jordan标准型

$$
P=(P(\xi_{11}),\ldots,P(\xi_{1n_1}),\ldots,P(\xi_{i1}),\ldots,P(\xi_{in_i}),\ldots,P(\xi_{s1}),\ldots,P(\xi_{sn_s}))
$$

$$
A=P\begin{pmatrix}
J_1(\lambda_1) & & & & & & & & & & & & & & \\
& J_2(\lambda_1) & & & & & & & & & & & & & \\
& & \ddots & & & & & & & & & & & & \\
& & & J_{n_1}(\lambda_1) & & & & & & & & & & & \\
& & & & J_1(\lambda_2) & & & & & & & & & & \\
& & & & & J_2(\lambda_2) & & & & & & & & & \\
& & & & & & \ddots & & & & & & & & \\
& & & & & & & J_{n_2}(\lambda_2) & & & & & & & \\
& & & & & & & & \ddots & & & & & & \\
& & & & & & & & & J_1(\lambda_s) & & & & & \\
& & & & & & & & & & J_2(\lambda_s) & & & & \\
& & & & & & & & & & & \ddots & & & \\
& & & & & & & & & & & & J_{n_s}(\lambda_s) & &
\end{pmatrix}P^{-1}
$$

矩阵的分解

1. 三角分解

设矩阵$A\in R^{n\times n}$, 使用 Gauss消元法即初等行变换将矩阵变换为上三角矩阵或下三角矩阵, 记上三角矩阵为U, 下三角矩阵为V, 初等行变换矩阵为P, 则有

$$
\begin{array}{ccc}
(A|E)\sim(U|P) & or & (A|E)\sim(V|P) \\
PA=U & or & PA=V \\
L=P^{-1} & or & L=P^{-1} \\
A=LU & or & A=LV
\end{array}
$$

2. 满秩分解

3. 奇异值分解

4. UR分解

5. Schur分解

6. 正规矩阵

数值分析

假设一组互异的插值点$(x_0,y_0),(x_1,y_1),(x_2,y_2),\ldots,(x_n,y_n)$是从一个$m$次多项式函数$p_m(x)$采样得到的, 且$m\le n$, 那么有这组插值点得到的插值多项式$P_n(x)$唯一存在, 且

$$
P_n(x)=p_m(x).
$$

插值

1. Lagrange插值

1.1. 插值方法

给定$n+1$个点$(x_0,y_0),(x_1,y_1),(x_2,y_2),\ldots,(x_n,y_n)$
插值基函数: $l_i(x)=\prod_{j=0,j\neq i}^{n}\frac{x-x_j}{x_i-x_j}$
插值函数: $L_n(x)=\sum_{i=0}^{n}y_i l_i(x)$

插值基函数的性质如下:

1. $\sum_{i=0}^{n} l_i(x) = 1$;
2. $l_i(x_j) = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$

1.2. 误差分析

$$R_n(x) = f(x) - L_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{i=0}^{n} (x - x_i)$$

2. Newton插值

2.1. 插值方法

给定$n+1$个点$(x_0, y_0), (x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$
插值函数: $N_n(x) = y_0 + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) + \cdots + f[x_0, x_1, \ldots, x_n](x - x_0)(x - x_1)\ldots(x - x_{n-1})$

差商:

$$\begin{gathered} f[x_0, x_1] = \tfrac{y_1 - y_0}{x_1 - x_0}, f[x_i, x_{i+1}] = \tfrac{y_{i+1} - y_i}{x_{i+1} - x_i} \\ f[x_0, x_1, x_2] = \tfrac{f[x_1, x_2] - f[x_0, x_1]}{x_2 - x_0} \\ f[x_0, x_1, x_2, x_3] = \tfrac{f[x_1, x_2, x_3] - f[x_0, x_1, x_2]}{x_3 - x_0} \\ \cdots \\ f[x_0, x_1, \ldots, x_n] = \tfrac{f[x_1, x_2, \ldots, x_n] - f[x_0, x_1, \ldots, x_{n-1}]}{x_n - x_0} \end{gathered}$$

前向插值:
$N_n(x) = y_0 + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) + \cdots + f[x_0, x_1, \ldots, x_n](x - x_0)(x - x_1)\ldots(x - x_{n-1})$

后向插值:
$N_n(x) = y_n + f[x_n, x_{n-1}](x - x_n) + f[x_n, x_{n-1}, x_{n-2}](x - x_n)(x - x_{n-1}) + \cdots + f[x_n, x_{n-1}, \ldots, x_0](x - x_n)(x - x_{n-1})\ldots(x - x_1)$

2.2. 差分与等距的牛顿插值

给定等间距的$n+1$个点$(x_0, y_0), (x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$, 其中$x_n = x_0 + nh$

2.3. 误差分析

前向插值误差: $R_n(x) = f(x) - N_n(x_0 + th) = \frac{t(t-1)\ldots(t-n)}{(n+1)!} h^{n+1} f^{(n+1)}(\xi), \xi \in (x_0, x_n)$
后向插值误差: $R_n(x) = f(x) - N_n(x_n - th) = \frac{t(t+1)\ldots(t+n)}{(n+1)!} h^{n+1} f^{(n+1)}(\xi), \xi \in (x_0, x_n)$

3. Hermite插值

拟合

1. 函数的最佳逼近

设函数$f(x) \in C[a, b]$, 用n次多项式$s(x) = \sum_{i=0}^{n} a_0 x^i$做最佳平方逼近. 求得一组参数$a_0^*, a_1^*, \ldots, a_n^*$, 使得误差函数值最小, 即

$$(a_0^*, a_1^*, \ldots, a_n^*) = \min_{a_0, a_1, \ldots, a_n} e(x) = \min_{a_0, a_1, \ldots, a_n} \int_a^b (f(x) - s(x))^2 dx$$

对误差函数计算偏导数可得

$$\frac{e(x)}{a_k} = 2 \int_a^b (f(x) - s(x)) x^k dx$$

由极值的必要条件可得

$$\begin{gathered} \tfrac{e(x)}{a_0} = 0 \\ \tfrac{e(x)}{a_1} = 0 \\ \\ \tfrac{e(x)}{a_n} = 0 \end{gathered}$$

现做如下记号:

$$\begin{gathered} \phi_k = x^k \\ (\phi_m, \phi_n) = \textstyle\int_a^b x^{m+n} dx \\ (\phi_n, f) = \textstyle\int_a^b x^n f(x) dx \end{gathered}$$

则极值条件可简化为

$$\begin{pmatrix} (\phi_0,\phi_0) & (\phi_0,\phi_1) & \dots & (\phi_0,\phi_n) \\ (\phi_1,\phi_0) & (\phi_1,\phi_1) & \dots & (\phi_1,\phi_n) \\ & & \ddots & \\ (\phi_n,\phi_0) & (\phi_n,\phi_1) & \dots & (\phi_n,\phi_n) \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \\ a_n \end{pmatrix} = \begin{pmatrix} (\phi_0,f) \\ (\phi_1,f) \\ \\ (\phi_n,f) \end{pmatrix}$$

该矩阵方程的解即为所求$a_0^*, a_1^*, \dots, a_n^*$.

2. 正交多项式

2.1. Legendre多项式:

- 表达式: $P_0(x) = 1, P_n(x) = \frac{1}{2^n n!}\frac{d^n}{dx^n}(x^2-1)^n$
- 正交性: $\int_{-1}^{1} P_m(x)P_n(x)dx = \begin{cases} 0, & m \neq n \\ \frac{2}{2n+1}, & m = n \end{cases}$
- 奇偶性: $P_n(-x) = (-1)^n P_n(x)$
- 递推关系: $(n+1)P_{n+1}(x) = (2n+1)xP_n(x) - nP_{n-1}(x)$

2.2. Chebyshev多项式

3. 曲线拟合的最小二乘法

现有若干数据点$(x_1,y_1),(x_2,y_2),\dots,(x_m,y_m)$, 欲用一组基函数$\phi_0(x),\phi_1(x),\dots,\phi_n(x)$进行拟合, 设拟合结果为$\hat{y} = \sum\limits_{i=0}^{n} a_i\phi_i(x)$. 为便于表示, 假设待拟合的数据点均为函数$y = f(x)$的采样结果, 即$y_i = f(x_i)$. 现使用最小二乘法计算相关系数.
设误差函数$e(a_0,a_1,\dots,a_n)$为

$$e(a_0,a_1,\dots,a_n) = \sum_{i=1}^{m}(\hat{y}_i - y_i)^2$$

则最佳系数可表示为

$$(a_0^*,a_1^*,\dots,a_n^*) = \min_{a_0,a_1,\dots,a_n} e(a_0,a_1,\dots,a_n)$$

根据极值的必要条件可得

$$\tfrac{e}{a_k} = 2\sum_{i=1}^{m}\phi_k(x_i)(\hat{y}_i - y_i) = 0$$

定义内积为

$$(\phi_p,\phi) = \sum_{i=1}^{m}\phi_p(x_i)\phi(x_i)$$
$$(\phi_p,f) = \sum_{i=1}^{m}\phi_p(x_i)f(x_i)$$

则

$$\frac{e}{a_k} = 2\sum_{i=0}^{n}a_i(\phi_k,\phi_i) - 2(\phi_k,f)$$

进而可得到系数方程

$$\begin{pmatrix} (\phi_0,\phi_0) & (\phi_0,\phi_1) & \dots & (\phi_0,\phi_n) \\ (\phi_1,\phi_0) & (\phi_1,\phi_1) & \dots & (\phi_1,\phi_n) \\ & & \ddots & \\ (\phi_n,\phi_0) & (\phi_n,\phi_1) & \dots & (\phi_n,\phi_n) \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \\ a_n \end{pmatrix} = \begin{pmatrix} (\phi_0,f) \\ (\phi_1,f) \\ \\ (\phi_n,f) \end{pmatrix}$$

该矩阵方程的解即为最佳系数$a_0^*, a_1^*, \dots, a_n^*$

数值积分

- Simpson公式: $\int_a^b f(x)dx \approx \frac{b-a}{6}[f(a) + 4f(\frac{a+b}{2}) + f(b)]$
- 梯形公式: $\int_a^b f(x) \approx \frac{b-a}{2}[f(a) + f(b)]$

数值积分方法是通过在区间$[a,b]$上选取若干个点, 以这若干点的函数值作为$\int_a^b f(x)dx$的估计值, 如下所示,

$$\int_a^b f(x)dx \approx \sum_{i=0}^{k} A_k f(x_k)$$

其中, A_k为求积系数, x_k为求积节点.

代数精度: 若求积公式对m阶多项式准确成立, 而对$m+1$不一定准确成立, 则称求积公式具有m阶代数精度. 一般来说, 分别令$f(x)$等于$1, x, x^2, \ldots$, 即可求得对应的求积系数.

1. 插值型求积公式

设函数$f(x) \in C[a,b]$, 在区间$[a,b]$上选取若干点$(x_0, f(x_0)), (x_1, f(x_1)), \ldots, (x_n, f(x_n))$, 由此, 函数$f(x)$的插值多项式为$f(x) \approx L_n(x) = \sum_{k=0}^{n} l_k(x) f(x_k)$, 则可以计算插值多项式的积分值以此近似表示原积分值

$$\int_a^b f(x)dx \approx \int_a^b L_n(x)dx = \sum_{k=0}^{n} A_k f(x_k)$$

其中, $A_k = \int_a^b l_k(x)dx$.

2. Newton-Cotes求积公式

3. 复化求积公式

3.1. 复化梯形公式

设函数$f(x) \in C^2[a,b]$, 在区间$[a,b]$等间距地选取若干个点$x_0, x_1, \ldots, x_n$, 间距为h, 则复化梯形公式为

$$\int_a^b f(x)dx = \sum_{k=0}^{n-1} \int_{x_k}^{x_{k+1}} f(x)dx \approx \frac{h}{2} \sum_{k=0}^{n-1} [f(x_k) + f(x_{k+1})]$$

其误差余项为

$$R_n(f) = -\frac{b-a}{12} h^2 f^{(2)}(\xi), \xi \in (a,b)$$

误差项推导如下:
对于误差项$R_n(f)$

$$R_n(f) = \int_a^b f(x)dx = \sum_{k=0}^{n-1} \int_{x_k}^{x_{k+1}} f(x)dx - \frac{h}{2} \sum_{k=0}^{n-1} [f(x_k) + f(x_{k+1})] = \sum_{k=0}^{n-1} \{\int_{x_k}^{x_{k+1}} f(x)dx - \frac{h}{2}[f(x_k) + f(x_{k+1})]\}$$

现考虑

$$R_n(f) = \sum_{k=0}^{n-1} \{\int_{x_k}^{x_{k+1}} f(x)dx - \frac{h}{2}[f(x_k) + f(x_{k+1})]\}$$

该式可变化为

$$R_n(f) = \sum_{k=0}^{n-1} \{\int_{x_k}^{x_{k+\frac{1}{2}}} [f(x) - f(x_k)]dx + \int_{x_{k+\frac{1}{2}}}^{x_{k+1}} [f(x) - f(x_{k+1})]dx\}$$

由于

$$f(x) = f(x_k) + f^{(1)}(x_k)(x - x_k) + \tfrac{1}{2} f^{(2)}(\xi_k)(x - x_k)^2$$
$$f(x) = f(x_{k+1}) + f^{(1)}(x_{k+1})(x - x_{k+1}) + \tfrac{1}{2} f^{(2)}(\xi_{k+1})(x - x_{k+1})^2$$

则$R_n(f)$可变化为

$$R_n(f) = \sum_{k=0}^{n-1} [\frac{h^2}{8} f^{(1)}(x_k) + \frac{1}{2} f^{(2)}(\alpha_k) \frac{1}{3} (\frac{h}{2})^3 - \frac{h^2}{8} f^{(1)}(x_{k+1}) + \frac{1}{2} f^{(2)}(\alpha_{k+1}) \frac{1}{3} (\frac{h}{2})^3]$$

根据拉格朗日中值定理与介值定理, 化简得

$$R_n(f) = \sum_{k=0}^{n-1} [-\frac{h^3}{8} f^{(2)}(\beta_k) + f^{(2)}(\gamma_{k+1}) \frac{1}{3} (\frac{h}{2})^3] = \sum_{k=0}^{n-1} [-\frac{1}{8} f^{(2)}(\beta_k) h^3 + \frac{1}{24} f^{(2)}(\gamma_{k+1}) h^3] = \sum_{k=0}^{n-1} \frac{1}{12} [-\frac{3}{2} f^{(2)}(\beta_k) + \frac{1}{2} f^{(2)}(\gamma_{k+1})] h^3$$

待续

3.2. 复化Simpson公式

设函数$f(x) \in C^2[a,b]$, 在区间$[a,b]$等间距地选取若干个点$x_0, x_1, \ldots, x_n$, 间距为h, 则复化梯形公式为

$$\int_a^b f(x)dx = \sum_{k=0}^{n-1} \int_{x_k}^{x_{k+1}} f(x)dx \approx \frac{h}{6} \sum_{k=0}^{n-1} [f(x_k) + 4f(x_{k+\frac{1}{2}}) + f(x_{k+1})]$$

其误差余项为

$$R_n(f) = -\frac{b-a}{180} (\frac{h}{2})^4 f^{(4)}(\xi), \xi \in (a,b)$$

4. Gauss型求积公式

对于函数$f(x) \in C[a,b]$, 在该曲线选择相异的若干个点$x_0, x_1, \ldots, x_n$, 使插值型求积公式$\int_a^b f(x)dx \approx \sum_{k=0}^n A_k f(x_k)$具有$2n+1$阶代数精度.

方程求解

微分方程求解

对于方程

$$\begin{cases} y' = f(x, y(x)), \quad a \le x \le b \\ y(a) = y_0 \end{cases}$$

1. Euler方法

显式Euler公式: $y_{n+1} = y_n + hf(x_n, y_n)$
隐式Euler公式: $y_{n+1} = y_n + hf(x_{n+1}, y_{n+1})$
梯形公式: $y_{n+1} = y_n + \frac{h[f(x_{n+1}, y_{n+1}) + f(x_n, y_n)]}{2}$

1.1. 改进的Euler方法

$$\hat{y}_{n+1} = y_n + hf(x_n, y_n)$$
$$y_{n+1} = y_n + \frac{h[f(x_{n+1}, \hat{y}_{n+1}) + f(x_n, y_n)]}{2}$$

1.2. 局部截断误差

对于显式Euler方法, 其截断误差估计如下:
假设方法可精确求解y_n, 即$y_n = y(x_n)$, 那么其截断误差表示为

$$e_{n+1} = y(x_{n+1}) - y_{n+1}$$

代入迭代方程可得

$$e_{n+1} = y(x_{n+1}) - y_n - hf(x_n, y_n) = [y(x_{n+1}) - y(x_n)] - h(f(x_n, y_n))$$

进一步可得

$$e_{n+1} = y'(x_n)h + \frac{1}{2}y''(x_n)h^2 + O(h^3) - hf(x_n, y_n)$$

代入微分方程可得

$$e_{n+1} = \frac{1}{2}y''(x_n)h^2 + O(h^3)$$

其中, $\frac{1}{2}y''(x_n)h^2$为误差主项, 因此, 可称显式Euler方法具有一阶精度.

对于某一迭代方法, 其截断误差一般表示为

$$e_{n+1} = \phi(x_n, y_n)h^{p+1} + O(h^{p+2}) \quad or \quad e_{n+1} = O(h^{p+1})$$

并称该方法具有p阶精度.

2. Runge-Kutta方法

3. 单步法的收敛性与稳定性

对于单步法, 其迭代方程为

$$y_{n+1} = y_n + h\phi(x_n, y_n, h)$$

现讨论其收敛性, 对于单步法, 若满足以下条件, 则称该方法是收敛的

$$\lim_{h \to 0, n \to \infty} y_n = y(x_n)$$

其中, 当$h \to 0$时, $n \to \infty$.
现讨论其稳定性

线性方程组求解

范数与条件数

1. 向量范数

$$||x||_\infty = \mathop{\mathrm{ma}}_{1\le i\le n} |x_i|$$
$$||x||_1 = \sum_{i=1}^{n} |x_i|$$
$$||x||_2 = (\sum_{i=1}^{n} x_i^2)^{\frac{1}{2}}$$
$$||x||_p = (\sum_{i=1}^{n} |x_i|^p)^{\frac{1}{p}}$$

2. 矩阵范数

$$||A||_\infty = \mathop{\mathrm{ma}}_{1\le i\le n} \sum_{j=1}^{n} |a_{ij}|, \text{称为}A\text{的行范数}$$
$$||A||_1 = \mathop{\mathrm{ma}}_{1\le j\le n} \sum_{i=1}^{n} |a_{ij}|, \text{称为}A\text{的列范数}$$
$$||A||_2 = \sqrt{\lambda_{max}}, \text{称为}A\text{的}2-\text{范数}, \text{其中}\lambda_{max}\text{为}A^TA\text{的最大特征值}.$$

矩阵范数与向量范数有如下关系:

$$||Ax||_p \le ||A||_p||x||_p$$

3. 条件数

设矩阵$A \in R^{n\times n}$为非奇异矩阵, 则其条件数定义为

$$\mathrm{nd}(A)_p = ||A^{-1}||_p|||A||_p$$

特殊地,

$$ond_2(A) = \sqrt{\frac{\lambda_{max}}{\lambda_{min}}}$$

矩阵方程的迭代解法

对于矩阵方程

$$Ax = b$$

若将矩阵A分解为$A = -N$, 且为非奇异的, 则原方程化为

$$x = Nx + b$$

进而有

$$x = {}^{-1}Nx + {}^{-1}b$$

由此, 可确立迭代方程

$$x_{n+1} = {}_{-1}Nx_n + {}^{-1}b$$

1. Jacobi 迭代

对于矩阵$A \in R^{n\times n}$, 将其分解为以下形式

$$A = D + L + U$$
$$D = diag(a_{11}, a_{22}, \ldots, a_{nn}),$$
$$L = \begin{pmatrix} 0 & a_{12} & a_{13} & \ldots & a_{1n} \\ 0 & 0 & a_{23} & \ldots & a_{2n} \\ & & & \ddots & \\ 0 & 0 & 0 & \ldots & 0 \end{pmatrix}$$
$$U = A - D - L$$

由此确立迭代方程

$$x_{n+1} = D^{-1}(L+U)x_n + D^{-1}b$$

2. Gauss-Seidel迭代

对于矩阵$A \in R^{n\times n}$, 将其分解为以下形式

$$
\begin{gathered}
A = D + L + U \\
D = diag(a_{11}, a_{22}, \ldots, a_{nn}), \\
L = \begin{pmatrix} 0 & a_{12} & a_{13} & \ldots & a_{1n} \\ 0 & 0 & a_{23} & \ldots & a_{2n} \\ & & & \ddots & \\ 0 & 0 & 0 & \ldots & 0 \end{pmatrix} \\
U = A - D - L
\end{gathered}
$$

设$D + L$可逆, 由此确立迭代方程

$$
x_{n+1} = -(D+L)^{-1}Ux_n + (D+L)^{-1}b
$$

3. 迭代解法的收敛性分析

对于迭代方程

$$
x_{n+1} = Bx_n + F
$$

该迭代方程收敛的充分必要条件是$(B) < 1$.

非线性方程迭代求根

对于方程$f(x) = 0$, 将其修改为$x = \phi(x)$, 进而得到迭代方程

$$
x_{n+1} = \phi(x_n)
$$

现讨论该迭代方程的收敛性.
若$\phi(x)$在$[a, b]$上满足以下条件:

1. $\forall x \in [a, b], \phi(x) \in [a, b]$;
2. $\exists L \in [0, 1), \forall x \in [a, b], |\phi'(x)| \leq L$.

则方程$x = \phi(x)$在$[a, b]$上有唯一解x^*, 且在迭代过程中对于任意初值$x_0 \in [a, b]$均收敛于方程$x = \phi(x)$的根. 且误差估计为

$$
|x_k - x^*| \leq \frac{1}{1-L}|x_{k+1} - x_k|
$$

1. 收敛阶

对于迭代方程$x_k = \phi(x_{k-1})$, 定义误差为$e_k = x_k - x^*$, 其中x^*为方程的精确解, 若存在正实数$p \leq 1$与正实数, 使得

$$
\lim_{k \to \infty} \frac{|e_{k+1}|}{|e_k|^p} =
$$

1. 若$p = 1$, 且$\in (0, 1)$, 则称其为线性收敛;
2. 若$p > 1$, 则称其为超线性收敛;
3. 若$p = 2$, 则称其为平方收敛.

对于方程$x = \phi(x)$, 若满足

1. x^*为方程的根, 迭代过程为$x_{k+1} = \phi(x_k)$;
2. $\phi(x)$在x^*的某邻域内p次连续可微(p 2);
3. $\phi'(x^*) = \phi''(x^*) = \cdots = \phi^{(p-1)}(x^*) = 0$, 且$\phi^{(p)}(x^*) \neq 0$;

则当初值x_0充分接近x^*时, 迭代过程是p阶收敛的, 且

$$
\lim_{k \to \infty} \frac{e_{k+1}}{e_k^p} = \frac{\phi^{(p)}(x^*)}{p!} \neq 0
$$

2. Newton迭代法

Newton迭代序列:

$$
x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}
$$

对于方程$f(x) = 0$, 若满足条件

1. $f(x)$在根x^*附近二阶连续可微;
2. $f'(x^*) \neq 0$;

则存在x^*的一个领域R $x||x - x^*| \leq$ 使得对于任意初值$x_0 \in R$, Newton迭代序列$\{x_k\}$收敛于x^*, 并有

$$\lim_{k\to\infty}\frac{e_{k+1}}{e_k^2}=\frac{f''(x^*)}{2f'(x^*)}$$

其中$e_k=x_k-x^*$.

3. Newton弦截法

迭代序列:

$$x_{k+1}=x_k-\frac{f(x_k)}{f(x_k)-f(x_{k-1})}(x_k-x_{k-1}),k=1,2,\ldots$$

概率论与数理统计

基本概念

1. 样本

设总体X的分布函数为$F(x)$(概率密度函数为$f(x)$或分布律为$p\{X=x^{(i)}\}=p(x^{(i)})$), 则来自总体$X$的样本$(X_1,X_2,\ldots,X_n)$的分布函数为$\prod_{i=1}^n F(x_i)$(概率密度函数为$\prod_{i=1}^n f(x_i)$或分布律为$\prod_{i=1}^n p(x_i)$).

2. 统计量

设样本$(X_1,X_2,\ldots,X_n)$是从总体X中采样得到的样本, 若$f(X_1,X_2,\ldots,X_n)$为一个函数, 且不含任何未知参数, 则$f(X_1,X_2,\ldots,X_n)$为一个统计量.

常见的统计量如下:

- $\overline{X}=\frac{1}{n}\sum\limits_{i=1}^n X_i$
- $S_n^2=\frac{1}{n}\sum\limits_{i=1}^n(X_i-\overline{X})^2=\frac{1}{n}\sum\limits_{i=1}^n X_i^2-\overline{X}^2$
- $S_n^{*2}=\frac{1}{n-1}\sum\limits_{i=1}^n(X_i-\overline{X})^2$为修正样本方差, 简称样本方差, 为方差的无偏估计量
- $A_k=\frac{1}{n}\sum\limits_{i=1}^n X_i^k$为样本$k$阶原点矩
- $B_k=\frac{1}{n}\sum\limits_{i=1}^n(X_i-\overline{X})^k$为样本$k$阶中心距

3. 经验分布函数

对总体X做n次独立检验, 得到检验结果$x_1,x_2,\ldots,x_n$,

4. 抽样分布

4.1. $\mathcal{X}^2$分布

设随机变量$X_1,X_2,\ldots,X_n$相互独立, 且均服从标准正太分布$N(0,1)$, 则称随机变量

$$\mathcal{X}_n^2=\sum_{i=1}^n X_i^2$$

服从自由度为n的$\mathcal{X}^2$分布, 即$\mathcal{X}_n^2\sim\mathcal{X}^2(n)$.

进一步地, 若这一组随机变量中存在m个彼此独立的线性约束条件, 即

$$\begin{aligned}\sum_{i=1}^n a_{1i}X_i&=\epsilon_1\\ \sum_{i=1}^n a_{2i}X_i&=\epsilon_2\\ &\cdots\\ \sum_{i=1}^n a_{mi}X_i&=\epsilon_m\end{aligned}$$

则称$\mathcal{X}_n^2=\sum\limits_{i=1}^n X_i^2$的自由度为$n-m$, 即$\mathcal{X}_n^2\sim\mathcal{X}^2(n-m)$.

相关性质如下:

- 性质一: $E(\mathcal{X}_n^2)=n, D(\mathcal{X}_n^2)=2n$
- 性质二: $\mathcal{X}_1^2\sim\mathcal{X}^2(n),\mathcal{X}_2^2\sim\mathcal{X}^2(m)$, 则$\mathcal{X}_1^2+\mathcal{X}_2^2\sim\mathcal{X}^2(n+m)$

4.2. t分布

设随机变量$X \sim N(0,1), Y \sim \mathcal{X}^2(n)$, 且$X$与$Y$相互独立, 则称随机变量

$$T = \frac{X}{\sqrt{\frac{Y}{n}}}$$

服从自由度为n的t分布.

相关性质如下:

- 性质一: 设$T \sim t(n)$, 当$n > 2$时, $E(T) = 0, D(T) = \frac{n}{n-2}$
- 性质二: 设$T \sim t(n)$, $\phi_T(x)$为概率密度函数, 则$\lim\limits_{n\to\infty} \phi_T(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}$

4.3. F分布

设随机变量$X_1 \sim \mathcal{X}^2(n_1), X_2 \sim \mathcal{X}^2(n_2)$, 且$X$与$Y$相互独立, 则称随机变量

$$F = \frac{X_1/n_1}{X_2/n_2}$$

服从自由度为(n_1, n_2)的F分布, 记为$F \sim F(n_1, n_2)$, 其中n_1为第一自由度, n_2为第二自由度.

相关性质如下:

- 性质一: $E(F) = \frac{n_2}{n_2-2}(n_2 > 2), D(F) = \frac{2n_2^2(n_1+n_2-2)}{n_1(n_2-2)^2(n_2-4)}(n_2 > 4)$
- 性质二: $F \sim F(n_1, n_2), \frac{1}{F} \sim F(n_2, n_1)$

4.4. 概率分布的分位数

设随机变量X, 对于给定的实数α, 若存在$X_\alpha = f(\alpha)$, 使得

$$p\{X > X_\alpha\} = \alpha$$

则称X_α为X的上侧分位数.

5. 均值与方差

设相互独立的随机变量$X_1, X_2, \ldots, X_n$, 其均值与方差分别为$E_1, E_2, \ldots, E_n$, $D_1, D_2, \ldots, D_n$, 则有

$$E(\sum_{i=1}^n a_i X_i + b) = \sum_{i=1}^n a_i E_i + b$$
$$D(\sum_{i=1}^n a_i X_i + b) = \sum_{i=1}^n a_i^2 D_i$$

若该组随机变量不相互独立, 则

$$E(\sum_{i=1}^n a_i X_i + b) = \sum_{i=1}^n a_i E_i + b$$
$$D(\sum_{i=1}^n a_i X_i + b) = \sum_{i=1}^n a_i^2 D_i + 2\sum_{i=1}^n \sum_{j=i+1}^n a_i a_j Cov(X_i, X_j)$$

6. 抽样分布定理

6.1. 均值的分布

6.1.1. 正态总体均值与方差的分布

设随机变量$X_1, X_2, \ldots, X_n$为正态分布$N(\mu, \sigma)$的一组样本, 则其任一线性组合

$$U = \sum_{i=1}^n a_i X_i$$

仍为正态分布, 即$U \sim N(\mu \sum\limits_{i=1}^n a_i, \sigma^2 \sum\limits_{i=1}^n a_i^2)$. 特殊地, $a_i = \frac{1}{n}, i = 1, 2, \ldots, n$时, $U = \overline{X} \sim N(\mu, \frac{\sigma^2}{n})$.
该样本的方差服从如下分布:

$$\frac{nS_n^2}{\sigma^2} = \frac{(n-1)S^{*2}}{\sigma^2} = \frac{1}{\sigma^2}\sum_{i=1}^n (X_i - \overline{X})^2 \sim \mathcal{X}^2(n-1)$$

且$\overline{X}$与S_n^2或S_n^{*2}独立.
对于统计量$T = \frac{\overline{X}-\mu}{S_n^{*2}}\sqrt{n}$服从以下分布

$$T = \frac{\overline{X} - \mu}{S_n^{*2}}\sqrt{n} \sim t(n-1)$$

设随机变量$X_1, X_2, \ldots, X_{n_1}, Y_1, Y_2, \ldots, Y_{n_2}$分别为正态分布$N(\mu_1, \sigma_1)$, $N(\mu_2, \sigma_2)$的一组样本, $A_{n_1}^2, B_{n_2}^2$分别为这两组样本的方差的无偏统计量, 则统计量$F = \frac{A_{n_1}^2/\sigma_1^2}{B_{n_2}^2/\sigma_2^2}$服从以下分布

$$F = \frac{A_{n_1}^2/\sigma_1^2}{B_{n_2}^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 2)$$

设随机变量$X_1, X_2, \ldots, X_{n_1}, Y_1, Y_2, \ldots, Y_{n_2}$分别为正态分布$N(\mu_1, \sigma^2)$, $N(\mu_2, \sigma^2)$的一组样本, $A_{n_1}^2, B_{n_2}^2$分别为这两组样本的方差的无偏统计量, 则统计量$T = \frac{(\overline{X_1} - \overline{X_2}) - (\mu_1 - \mu_2)}{\sqrt{(n_1-1)A_{n_1}^2 + (n_2-1)B_{n_2}^2}} \sqrt{\frac{n_1 n_1 (n_1+n_2-2)}{n_1+n_2}}$服从以下分布

$$T = \frac{(\overline{X_1} - \overline{X_2}) - (\mu_1 - \mu_2)}{\sqrt{(n_1 - 1)A_{n_1}^2 + (n_2 - 1)B_{n_2}^2}} \sqrt{\frac{n_1 n_1 (n_1 + n_2 - 2)}{n_1 + n_2}} \sim t(n_1 + n_2 - 2)$$